Tareas varias voluntarias

David Cabezas Berrido

1 Resolución de sistemas de ecuaciones en R

La función `solve` de R, sirve para resolver sistemas de ecuaciones lineales. En concreto, ecuaciones del tipo $ax = b$, donde a es una matriz cuadrada real o compleja (la matriz de coeficientes del sistema) y b una matriz o un vector real o complejo. La función `solve(a,b)` devuelve la matriz o vector x que resuelve el sistema. Si se omite el parámetro b, se toma la matriz identidad, por lo que la función devuelve la inversa de a.

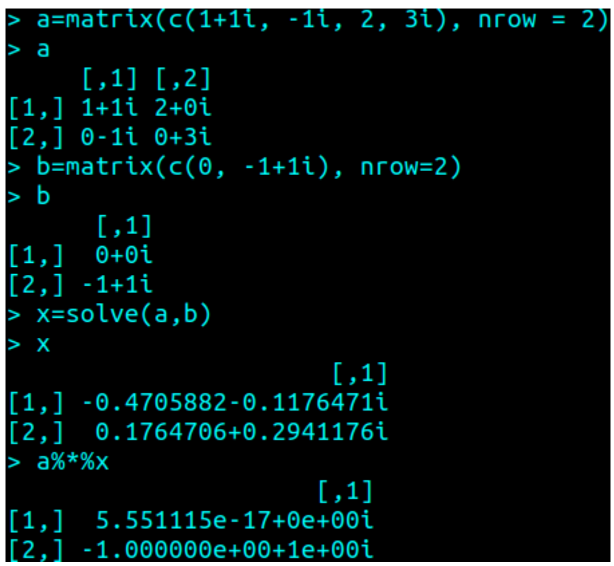

```
> a=matrix(c(1+1i, -1i, 2, 3i), nrow = 2)
> a
     [,1] [,2]
[1,] 1+1i 2+0i
[2,] 0-1i 0+3i
> b=matrix(c(0, -1+1i), nrow=2)
> b
      [,1]
[1,]  0+0i
[2,] -1+1i
> x=solve(a,b)
> x
                      [,1]
[1,] -0.4705882-0.1176471i
[2,]  0.1764706+0.2941176i
> a%*%x
                     [,1]
[1,]  5.551115e-17+0e+00i
[2,] -1.000000e+00+1e+00i
```

Figure 1: Ejemplo de uso de solve para resolver un sistema lineal complejo de dos ecuacioness.

En este ejemplo definimos una matriz compleja 2×2 a, un vector complejo b con 2 componentes, llamamos a la función solve para resolver el sistema y asignamos el resultado a la variable x. Después comprobamos que efectivamente x satisface la ecuación $ax = b$.

2 El paquete gráfico ggplot2

`ggplot2` es un paquete gráfico de R. Según https://ggplot2.tidyverse.org/index.html, está basado en el libro *The Grammar of Graphics*, de Leland Wilkinson. En la página https://www.rdocumentation.org/packages/ggplot2/versions/3.3.2 se encuentra una guía de instalación, una Cheatsheet, una descripción de las funciones del paquete y algunos tutoriales para dominarlo.

Probamos y explicamos un pequeño ejemplo encontrado en:
https://www.datanovia.com/en/lessons/introduction-to-ggplot2/, en el que representamos en un diagrama de dispersión (esto lo hacemos con `aes(x,y)`) en el que representamos la longitud (eje X) y anchura (eje Y) de los pétalos de las distintas flores. Elegimos un color y una forma diferentes para cada clase. Seleccionamos manualmente los colores en formato RGB hexadecimal: #FF0000 sería el rojo más puro e intenso posible, #00FF00 el verde más puro y #0000FF el azul puro.

```r
library(ggplot2) # Cargamos el paquete

# Elegimos las variables a representar en cada eje
ggplot(iris, aes(x = Petal.Length, y = Petal.Width))+
  # Para cada clase (especie) utilizamos un color y una forma
  geom_point(aes(color = Species, shape = Species))+
  # Elegimos los colores manualmente: Rojo, Verde y Azul
  scale_color_manual(values = c("#FF0000", "#00FF00", "#0000FF"))
```

Figure 2: Ejemplo de gráfico con `ggplot2`.

Este es el gráfico que generamos:

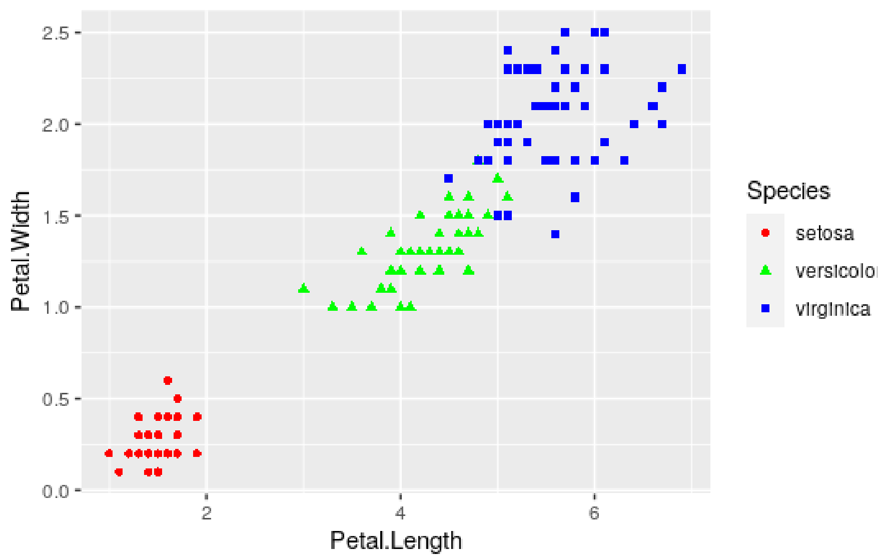

Figure 3: Gráfico generado

3 Método del codo para la selección del número de componentes principales

El método del codo, es una heurística que se utiliza para determinar el número de clusters en un dataset. Consiste en representar la proporción de varianza explicada en función del número de clusters y escoger el número de clusters en el que se produzca el codo de la curva.

Esta misma técnica se puede utilizar para elegir el número de componentes principales para describir los datos, sólo hay que representar la proporción de varianza acumulada por las n

primeras componponentes principales como función de n y elegir el valor de n con el código de la curva. También se puede hacer (como explica aquí) sobre el porcentaje de varianza explicada por cada componente princial, e identificar el valor de n a partir del cual la varianza explicada por cada posterior componente principal sea baja.

Ponemos como ejemplo el dataset de las concentraciones de elementos químicos en muestras de vidrio del paquete “archdata”. En lugar de como gráfico de barras, cambiamos la prepresentación a líneas y puntos para que sea más fácil identificar el codo de la curva.

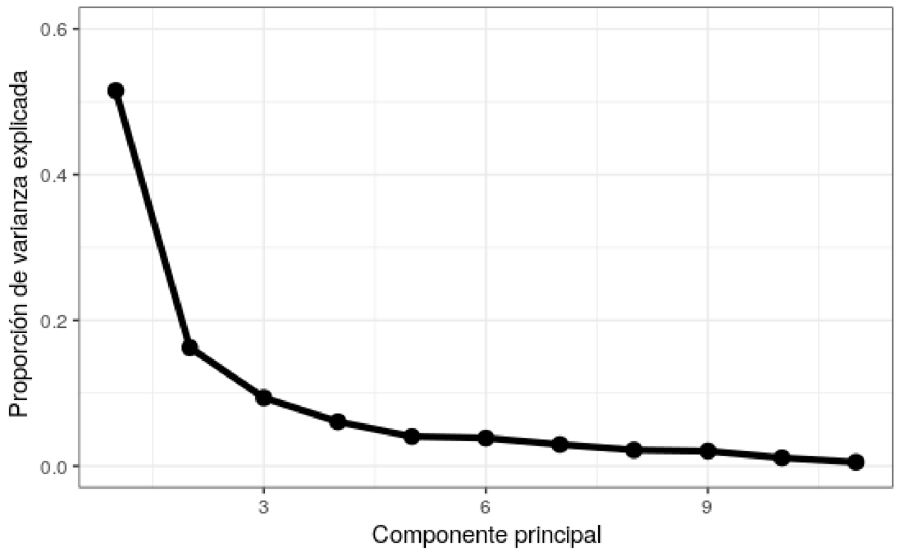

Figure 4: Curva de varianza explicada de cada componente principal.

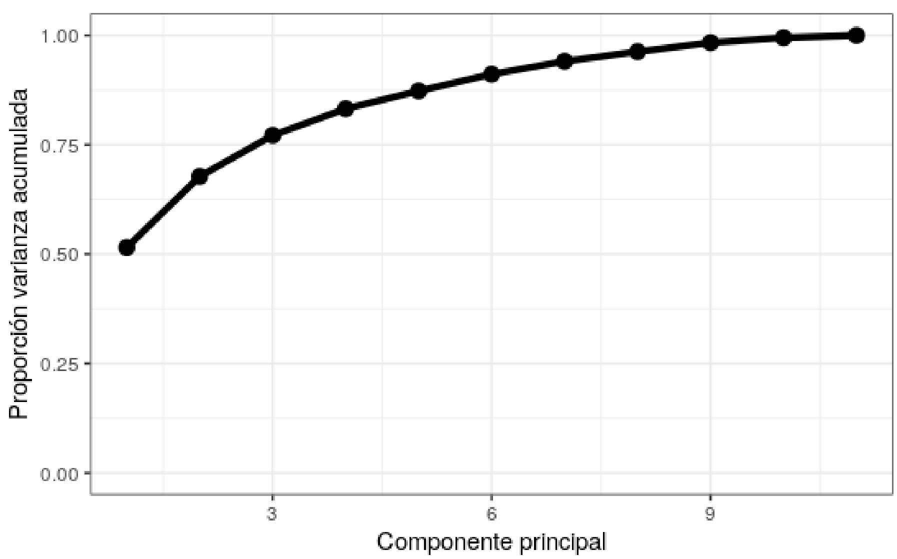

Figure 5: Curva de varianza explicada acumulada de cada componente principal.

En ambas curvas, podemos identificar el codo para el valor 3 del número de componentes principales.